

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH (UEH)
TRƯỜNG CÔNG NGHỆ VÀ THIẾT KẾ



ĐỒ ÁN MÔN HỌC

ĐỀ TÀI:

**ỨNG DỤNG PHƯƠNG PHÁP PHÂN LỚP DỰA TRÊN
MẪU THƯỜNG XUYÊN ĐỂ DỰ ĐOÁN KHẢ NĂNG
HỦY ĐẶT PHÒNG CỦA KHÁCH HÀNG**

Học phần: Máy Học

Nhóm Sinh Viên:

1. Võ Minh Nguyên
2. Nguyễn Phúc Bảo Nhân
3. Phan Đình Nhân
4. Nguyễn Quang Nhật
5. Nguyễn Thị Ngọc Nhi

Chuyên Ngành: Khoa Học Dữ Liệu

Khóa: K47

Giảng Viên: TS. Nguyễn An Tế

Thành phố Hồ Chí Minh , tháng 12 năm 2023

LỜI MỞ ĐẦU

Trong thời đại hội nhập toàn cầu, các trang web đặt phòng và mạng xã hội đã trở thành những cầu nối không thể thiếu, kết nối khách du lịch và nhà hàng - khách sạn trên phạm vi toàn cầu. Những nền tảng này không chỉ là nơi cho các doanh nghiệp và cá nhân trưng bày dịch vụ của mình, mà còn là công cụ đắc lực để khai thác trí tuệ nhân tạo (AI) trong việc tạo ra những đề xuất dịch vụ cá nhân hóa dựa trên sở thích và lịch trình của khách hàng.

Giờ đây, các thuật toán và phương pháp máy học được triển khai một cách tinh vi để phân tích và phân loại dịch vụ, từ đó đưa ra những đề xuất dịch vụ tương tự hoặc liên quan mà khách hàng tiềm năng có thể quan tâm. Điều này không chỉ nâng cao trải nghiệm đặt phòng trực tuyến của khách hàng, mà còn giúp các doanh nghiệp tối ưu hóa chiến lược kinh doanh của mình.

Bên cạnh đó, việc nắm bắt các yêu cầu về đặt phòng hoặc dịch vụ đi kèm thường xuyên của khách hàng là rất quan trọng. Điều này giúp các doanh nghiệp nhà hàng - khách sạn hiểu rõ hơn về hành vi của khách hàng, từ đó xác định hoặc phân loại khách hàng tiềm năng. Điều này không chỉ giúp tăng doanh số đặt phòng, mà còn giúp các doanh nghiệp xây dựng một mối quan hệ lâu dài và bền vững với khách hàng của mình.

Từ khóa: Nhà hàng - Khách sạn, Yêu cầu đặt phòng, Dịch vụ đi kèm, Phân loại khách hàng.

MỤC LỤC

LỜI MỞ ĐẦU.....	1
MỤC LỤC.....	2
CHƯƠNG I. TỔNG QUAN ĐỀ TÀI.....	4
1. Sơ lược đề tài.....	4
2. Mục tiêu nghiên cứu.....	4
3. Phương pháp nghiên cứu.....	5
4. Tài nguyên sử dụng.....	5
CHƯƠNG II. KHÁI NIỆM TỔNG QUÁT.....	6
1. Lựa chọn mẫu phổ biến.....	6
a. Apriori.....	6
b. FP-Growth.....	6
c. Kết luận.....	7
2. Các khái niệm quan trọng trong mẫu phổ biến.....	7
a. Item.....	7
b. Itemset.....	7
c. Size.....	8
d. Support.....	8
e. Ngưỡng hỗ trợ tối thiểu (minSup).....	8
f. Frequent Item.....	9
g. Frequent Itemset.....	9
3. Phương pháp phân lớp (SVM).....	9
CHƯƠNG III. CÁC BƯỚC XÂY DỰNG THUẬT TOÁN.....	11
1. Chuẩn bị dữ liệu.....	11
2. Khai thác mẫu phổ biến.....	11
3. Chọn lọc mẫu.....	14
4. Chuyển đổi mẫu phổ biến thành dạng đặc trưng.....	14
5. Xây dựng mô hình phân lớp.....	16
6. Sử dụng mô hình.....	17
CHƯƠNG IV. TỔNG QUAN BỘ DỮ LIỆU.....	17
1. Sơ lược về bộ dữ liệu.....	17
2. Mô tả thuộc tính của bộ dữ liệu.....	18
3. Tiền xử lý dữ liệu.....	19
a. Thăm dò dữ liệu.....	19

b. Làm sạch dữ liệu.....	21
c. Rời rạc hóa dữ liệu.....	23
CHƯƠNG V. ỨNG DỤNG GIẢI THUẬT TRÊN BỘ DỮ LIỆU.....	25
1. Chuẩn bị dữ liệu.....	25
2. Khai thác mẫu phổ biến và chọn lọc mẫu.....	26
3. Chuyển đổi mẫu phổ biến thành dạng đặc trưng.....	28
4. Xây dựng mô hình phân lớp.....	29
5. Sử dụng mô hình.....	30
CHƯƠNG VI. ĐÁNH GIÁ.....	31
1. Đánh giá mô hình.....	31
2. So sánh độ chính xác của mô hình phân lớp giữa tập dữ liệu sử dụng mẫu thường xuyên và không sử dụng mẫu thường xuyên.....	32
CHƯƠNG VII. KẾT LUẬN.....	33
PHỤ LỤC.....	35
1. Mã nguồn.....	35
2. Bảng phân công.....	35
3. Tài liệu tham khảo.....	35

CHƯƠNG I. TỔNG QUAN ĐỀ TÀI

1. Sơ lược đề tài

Trong bối cảnh số hóa toàn cầu, ngành dịch vụ nhà hàng và khách sạn đang phải đối mặt với nhiều thách thức trong việc tiếp nhận công nghệ mới, thậm chí còn nhiều hơn so với các ngành khác trong cùng lĩnh vực. Việc đánh giá chất lượng dịch vụ yêu cầu sự am hiểu về các quy tắc phức tạp và sự khác biệt cho mỗi loại dịch vụ. Tuy nhiên, trong một môi trường thiếu thông tin về khách hàng (NON - KYC) và mối quan hệ phức tạp với khách hàng, việc áp dụng quy trình đánh giá chất lượng truyền thống có thể gây ra xung đột với mục tiêu lợi nhuận kinh doanh.

Trong ngành này, việc hủy phòng của khách hàng tiềm ẩn rủi ro cho doanh nghiệp. Hủy phòng đột ngột có thể gây ra thiệt hại về doanh thu và lợi nhuận, đặc biệt khi doanh nghiệp đã chuẩn bị và phục vụ dựa trên đặt phòng đó. Hơn nữa, việc hủy phòng thường xuyên từ phía khách hàng có thể làm tổn hại đến uy tín và danh tiếng của doanh nghiệp, làm mất lòng tin của khách hàng và ảnh hưởng đến việc thu hút khách hàng mới trong tương lai.

Vì vậy, việc xác định và quản lý khả năng hủy phòng của khách hàng là rất quan trọng để giảm thiểu rủi ro và tối ưu hóa lợi nhuận cho doanh nghiệp. Thông qua bộ dữ liệu gốc, nhóm nghiên cứu có thể xác định khả năng hủy phòng của khách hàng dựa trên yêu cầu đặt phòng và dịch vụ đi kèm. Điều này giúp doanh nghiệp tránh được rủi ro về lợi nhuận và đóng góp vào việc đánh giá tiềm năng và chất lượng dịch vụ nhà hàng - khách sạn, từ đó mang lại hiểu biết sâu hơn về tương tác giữa các thuộc tính của khách hàng đặt phòng và ảnh hưởng của chúng đến chi phí dịch vụ của doanh nghiệp.

2. Mục tiêu nghiên cứu

Mục tiêu chính của nghiên cứu này là tìm hiểu và phân tích các yếu tố ảnh hưởng đến khả năng hủy phòng của khách hàng trong ngành nhà hàng - khách sạn. Điều này bao gồm việc xác định các thuộc tính của khách hàng và yêu cầu đặt phòng có liên quan đến việc hủy phòng.

Nghiên cứu cũng nhằm mục đích tìm hiểu về mối quan hệ giữa các yếu tố này và hoạt động dịch vụ hiện tại của doanh nghiệp. Điều này sẽ giúp doanh nghiệp tối ưu hóa quy trình đánh giá chất lượng dịch vụ, giảm thiểu rủi ro về lợi nhuận và tăng cường mối quan hệ với khách hàng.

Ngoài ra, thông qua việc phân tích và hiểu rõ hơn về các yếu tố này, doanh nghiệp có thể đưa ra các chiến lược và quyết định kinh doanh hiệu quả hơn, từ đó nâng cao chất lượng dịch vụ và tăng cường sự hài lòng của khách hàng. Điều này không chỉ

giúp tăng cường mối quan hệ với khách hàng hiện tại mà còn thu hút khách hàng mới, góp phần vào sự phát triển bền vững của doanh nghiệp.

3. Phương pháp nghiên cứu

Nhóm sử dụng nhiều phương pháp khác nhau linh hoạt theo nội dung nghiên cứu. Trong phương pháp phân lớp dựa trên mẫu thường xuyên, nhóm chia bài toán lớn thành hai bài toán nhỏ: tìm mẫu thường xuyên và học có giám sát:

- **Chương II:** Tập trung vào việc xây dựng khái niệm về thuật toán tìm mẫu phổ biến thông qua luật kết hợp như Apriori và FP-Growth. Ngoài ra, chương này cũng giới thiệu về mô hình học máy SVM được sử dụng để phân lớp trong bài toán.
- **Chương III:** Tạo ra một ví dụ minh họa cụ thể để xây dựng các bước phân lớp khách hàng dựa trên mẫu thường xuyên.
- **Chương IV:** Thực hiện áp dụng bài toán vào một bộ dữ liệu thực tế và đánh giá độ chính xác của việc dự đoán các tình huống có thể xảy ra với khách hàng, như việc hủy phòng hoặc không hủy phòng. Kết quả này sau đó được so sánh với thực tế để đánh giá hiệu quả của phương pháp.

4. Tài nguyên sử dụng

- Ngôn ngữ lập trình: Python
- Bộ dữ liệu Hotel Reservations Dataset từ Kaggle: [Hotel Reservations Dataset](#)

CHƯƠNG II. KHÁI NIỆM TỔNG QUÁT

1. Lựa chọn mẫu phổ biến

Tìm mẫu phổ biến trong khai phá dữ liệu là quy trình quan trọng trong việc khám phá thông tin ẩn, tìm ra các mẫu tương quan và các quy tắc của tập dữ liệu. Mục tiêu của phương pháp này là tìm ra các tập hợp phổ biến mà chúng xuất hiện cùng nhau với một tần suất đáng kể.

Hai thuật toán được sử dụng rộng rãi trong phương pháp chọn mẫu phổ biến là: Apriori và FP-Growth:

a. Apriori

- **Cấu trúc dữ liệu:** Apriori sử dụng một danh sách tần suất của các mục để lưu trữ thông tin về sự xuất hiện của chúng trong tập dữ liệu. Cấu trúc dữ liệu này được gọi là bảng hỗ trợ (Support Table).
- **Phương pháp tìm kiếm:** Apriori sử dụng một phương pháp tìm kiếm theo chiều rộng, trong đó các mục phổ biến được tạo ra từ các mục K-1 tập phổ biến. Thuật toán duyệt qua các mục trong tập dữ liệu và tạo ra các tập phổ biến có K mục bằng cách kiểm tra tần suất của chúng trong bảng hỗ trợ.
- **Tần suất tính toán:** Để tính toán tần suất, Apriori duyệt qua tập dữ liệu hai lần. Lần đầu tiên, thuật toán đếm số lần xuất hiện của từng mục và xây dựng bảng hỗ trợ. Lần thứ hai, thuật toán áp dụng các quy tắc kết hợp để tạo ra các tập phổ biến và tính toán tần suất của chúng.

b. FP-Growth

- **Cấu trúc dữ liệu:** FP-Growth sử dụng một cấu trúc dữ liệu gọi là FP-Tree để lưu trữ thông tin về các mục và tần suất của chúng trong tập dữ liệu. FP-Tree được xây dựng bằng cách duyệt qua tập dữ liệu một lần và xây dựng cây dựa trên tần suất.
- **Phương pháp tìm kiếm:** FP-Growth sử dụng một phương pháp tìm kiếm theo chiều sâu. Đầu tiên, thuật toán tạo FP-Tree từ tập dữ liệu đầu vào. Sau đó, nó sử dụng FP-Tree để tạo ra các tập phổ biến bằng cách duyệt qua cây và tạo ra các đường dẫn con từ mỗi nút lá.
- **Tần suất tính toán:** Tần suất tính toán trong FP-Growth được thực hiện thông qua việc xử lý cây FP-Tree. Khi xây dựng FP-Tree, thuật toán đếm số lần xuất hiện của từng mục và lưu trữ thông tin này trong cây. Khi tạo các tập

phổ biến, FP-Growth duyệt qua cây và tính toán tần suất của mỗi đường dẫn con.

c. Kết luận

Khi thực hiện phân lớp dựa trên mẫu phổ biến, sự lựa chọn giữa Apriori và FP-Growth có ý nghĩa khá quan trọng. Tuy nhiên, trong hầu hết các trường hợp, FP-Growth là phương pháp được ưu tiên hơn do nhiều lợi ích mà nó mang lại.

FP-Growth có một số ưu điểm so với Apriori:

- Đầu tiên, FP-Growth sử dụng cấu trúc dữ liệu FP-Tree, giúp tiết kiệm không gian lưu trữ so với bảng hỗ trợ của Apriori, đặc biệt là khi xử lý các tập dữ liệu lớn.
- Thứ hai, FP-Growth sử dụng phương pháp tìm kiếm theo chiều sâu, giúp thuật toán duyệt qua dữ liệu chỉ một lần để xây dựng FP-Tree và tạo ra các tập phổ biến. Điều này giúp giảm thời gian thực hiện so với Apriori, đặc biệt là khi tập dữ liệu lớn.

→ Vì vậy, trong toàn bộ nội dung được cung cấp dưới đây, nhóm sẽ sử dụng FP-Growth để tìm mẫu phổ biến cho bài toán phân lớp tiếp theo.

2. Các khái niệm quan trọng trong mẫu phổ biến

a. Item

Trong phân tích dữ liệu, một item đề cập đến một đơn vị dữ liệu đơn lẻ, một thuộc tính cụ thể hoặc một đối tượng trong tập dữ liệu.

Ví dụ:

Gọi $I = \{I1, I2, I3, \dots\}$ là tập hợp các sản phẩm (Items) được bán trong cửa hàng.

$I = \{\text{Sữa, Bánh quy, Nước ngọt, Cam, Chanh}\}$

b. Itemset

Một itemset là một tập hợp các item được tổ chức lại cùng nhau. Điều này có thể là một tập hợp con của các item trong dữ liệu hoặc một tập hợp các item hoàn chỉnh. Itemset có thể có kích thước từ 1 (item đơn lẻ) đến n (tập hợp tất cả các item có thể).

Ví dụ:

Gọi X là tập hợp mục tiêu (Itemset), nhằm xác định các sản phẩm xuất hiện cùng nhau trong một tập dữ liệu, với $X \subseteq I$.

$\{\text{Sữa, Bánh quy}\}$

c. Size

Kích thước tập (Size) được xác định dựa trên K số lượng các sản phẩm khác nhau có mặt trong cùng một tập hợp mục tiêu.

Ví dụ:

$\{\text{Sữa, Bánh quy}\} \rightarrow \text{Kích thước tập (Size)} = 2$

d. Support

Support (độ hỗ trợ) được sử dụng để đo lường tần suất xuất hiện của một itemset trong dữ liệu. Support được tính bằng tỷ lệ giữa số lần xuất hiện của itemset và tổng số mẫu trong dữ liệu.

Ví dụ:

$\{\text{Sữa, Bánh quy}\}$ cùng xuất hiện 3 lần trong tổng số 5 hóa đơn:

Mẫu $\{\text{Sữa, Bánh quy}\}$ với $\text{support} = 3/5 = 0.6$ (60%)

e. Ngưỡng hỗ trợ tối thiểu (minSup)

MinSup là ngưỡng hỗ trợ tối thiểu được đặt ra từ ban đầu để xác định các mẫu phổ biến. Với chỉ số này, cần phải cân nhắc trước khi lựa chọn, vì khi đặt ngưỡng minSup quá cao hoặc quá thấp trong thuật toán khai phá luật kết hợp có thể xảy ra những hiện tượng sau:

- **Ngưỡng minSup quá cao:**

Khi minSup được đặt quá cao, số lượng itemsets thỏa mãn ngưỡng này sẽ giảm đáng kể. Điều này có thể dẫn đến việc bỏ qua nhiều luật kết hợp quan trọng hoặc hiển thị một số luật kết hợp không có ý nghĩa. Tác động của việc đặt minSup quá cao là mất mát thông tin quan trọng và giảm khả năng tìm ra các mẫu dữ liệu ý nghĩa.

- **Ngưỡng minSup quá thấp**

Khi minSup được đặt quá thấp, số lượng itemsets thỏa mãn ngưỡng này sẽ tăng lên đáng kể. Điều này có thể dẫn đến một số vấn đề như:

- **Sự gia tăng về số lượng luật kết hợp:** Một minSup quá thấp có thể tạo ra quá nhiều luật kết hợp, trong đó có nhiều luật không có ý nghĩa hoặc không thực tế. Điều này làm tăng khối lượng dữ liệu được trả về và khó khăn khi phân tích và hiểu các luật quan trọng.
- **Overfitting:** Một minSup quá thấp có thể dẫn đến hiện tượng overfitting trong khai phá dữ liệu. Overfitting xảy ra khi mô hình học máy tạo ra các quy tắc quá phức tạp hoặc quá cụ thể để phù hợp với dữ liệu huấn

luyện, nhưng không thể tổng quát hóa tốt cho dữ liệu mới. Điều này có thể dẫn đến kết quả không đáng tin cậy và không thể áp dụng cho dữ liệu khác.

- Vì vậy, việc lựa chọn giá trị MinSup phù hợp là cần thiết để đảm bảo rằng các mẫu phổ biến tìm thấy có ý nghĩa và hữu ích trong quá trình khai phá dữ liệu, đồng thời tránh những tác động tiêu cực như Overfitting và tăng hao phí tính toán.

f. Frequent Item

Frequent item (mục phổ biến) là một item xuất hiện trong dữ liệu với tần suất đáng kể. Tần suất được xác định bằng cách đếm số lần xuất hiện của mỗi item trong dữ liệu. Một item được coi là phổ biến nếu tần suất xuất hiện của nó vượt qua một ngưỡng (minSup) được xác định trước.

Ví dụ:

Có tổng cộng 5 hóa đơn, với một ngưỡng tần suất 50%.

- Item {Sữa} xuất hiện trong 4 hóa đơn,
 - Item {Quần jean} xuất hiện trong 5 hóa đơn,
- Các item {Sữa} và {Quần jean} được xem là frequent items.

g. Frequent Itemset

Frequent itemset (tập hợp mục phổ biến) là một tập hợp các item mà cùng xuất hiện với tần suất đáng kể trong dữ liệu. Frequent itemset thường được xác định bằng cách đếm số lần xuất hiện của từng tập hợp item trong dữ liệu và so sánh với ngưỡng tần suất.

Ví dụ: Tiếp tục với ví dụ trên,

Mẫu {Sữa, Bánh quy} có support 0.6 nên được xem là frequent itemset (>50%).

3. Phương pháp phân lớp (SVM)

Phương pháp phân lớp SVM (Support Vector Machine) là một thuật toán học máy được sử dụng rộng rãi để phân loại các điểm dữ liệu vào các lớp khác nhau trong các bài toán phân loại. SVM là một phương pháp dựa trên việc tìm một siêu phẳng (hyperplane) trong không gian đặc trưng sao cho tối đa hóa khoảng cách giữa các điểm dữ liệu gần nhất của các lớp.

Ý tưởng cơ bản của SVM là chọn một siêu phẳng sao cho khoảng cách từ siêu phẳng đến điểm gần nhất của các lớp là lớn nhất. Điểm gần nhất của mỗi lớp được gọi là vector hỗ trợ (support vector), vì chúng "hỗ trợ" định nghĩa siêu phẳng phân lớp. Quá trình tìm siêu phẳng tối ưu này có thể được thực hiện thông qua một bài toán tối ưu hóa.

Ứng dụng SVM trong bài toán phân lớp dựa trên mẫu phổ biến:

Trong bài toán phân loại, việc ổn định mô hình và tránh overfitting là vô cùng quan trọng. SVM (Support Vector Machine) là một phương pháp phân lớp mà có thể giải quyết vấn đề này một cách hiệu quả. SVM có khả năng chịu được nhiễu và điều chỉnh overfitting thông qua các thông số như C (tham số điều chỉnh độ lỗi cho phân lớp sai) và các hàm kernel.

Ngoài ra, SVM tập trung vào tìm siêu phẳng tối ưu để phân chia các lớp dữ liệu, đặc biệt chú trọng đến các mẫu gần biên giới. Điều này làm cho SVM trở nên hữu ích trong trường hợp các mẫu phổ biến, tức là các mẫu dữ liệu quan trọng và thường xuyên xuất hiện. Các mẫu phổ biến thường nằm gần biên giới và có ảnh hưởng lớn đến quá trình phân loại. Bằng cách tập trung vào những mẫu này, SVM có khả năng định rõ siêu phẳng tối ưu và đưa ra quyết định phân lớp chính xác.

CHƯƠNG III. CÁC BƯỚC XÂY DỰNG THUẬT TOÁN

1. Chuẩn bị dữ liệu

Đầu tiên, nhóm nghiên cứu sẽ tiến hành biến đổi dữ liệu gốc để phù hợp với quá trình khai thác mẫu. Trong các bước tiếp theo, nhóm sẽ xây dựng giải thuật dựa trên bảng dữ liệu minh họa sau đây:

Khách hàng	Sản phẩm
KH1	Áo phong, Quần Jean, Giày thể thao
KH2	Áo phong, Quần Kaki, Mũ lưỡi trai
KH3	Áo phong, Áo khoác, Quần Kaki, Túi xách
KH4	Quần Jean, Mũ lưỡi trai, Túi xách
KH5	Áo phong, Quần Jean, Mũ lưỡi trai, Túi xách, Quần Kaki

2. Khai thác mẫu phổ biến

Nhóm sẽ sử dụng các thuật toán khai thác mẫu phổ biến, như: Apriori, FP-Growth, ECLAT, SPAM, Nhờ đó tìm ra các mẫu phổ biến từ dữ liệu đã chuẩn bị ban đầu. Các mẫu phổ biến có thể là các Itemset phổ biến, chuỗi phổ biến, cây phổ biến, đồ thị phổ biến, tùy thuộc vào dạng dữ liệu và yêu cầu của bài toán.

Ví dụ: Thông qua thuật toán FP-Growth, nhóm sẽ tìm ra các mẫu phổ biến từ bảng dữ liệu minh họa.

- Xây dựng F-List: Duyệt cơ sở dữ liệu ban đầu để xác định L_1 , sau đó nhóm sẽ sắp xếp lại L_1 theo thứ tự giảm dần của tần suất:

Sản phẩm	L_1
Áo phong	4
Quần Jean	3
Giày thể thao	1
Quần Kaki	3



Sản phẩm	F-List
Áo phong	4
Quần Jean	3
Quần Kaki	3
Mũ lưỡi trai	3

Mũ lưỡi trai	3
Áo khoác	1
Túi xách	3

Túi xách	3
Áo khoác	1
Giày thể thao	1

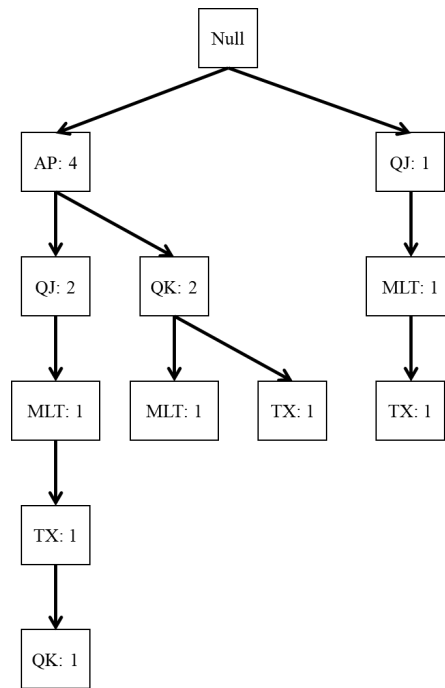
- Lựa chọn vật phẩm dựa trên ngưỡng tần suất xuất hiện (minSup) là 40%: Có 5 giao dịch, nên để thỏa mãn minSup = 0.4, nhóm sẽ xem xét giữ lại các mẫu xuất hiện ít nhất 2 lần (0.4×5). Sau đó, thực hiện loại bỏ các vật phẩm không đủ điều kiện ra khỏi bảng ban đầu:

Sản phẩm	F-List
Áo phong	4
Quần Jean	3
Quần Kaki	3
Mũ lưỡi trai	3
Túi xách	3

Loại: Áo khoác, Giày thể thao (Do có 1 lần xuất hiện)

Khách hàng	Sản phẩm
KH1	Áo phong, Quần Jean
KH2	Áo phong, Quần Kaki, Mũ lưỡi trai
KH3	Áo phong, Quần Kaki, Túi xách
KH4	Quần Jean, Mũ lưỡi trai, Túi xách
KH5	Áo phong, Quần Jean, Mũ lưỡi trai, Túi xách, Quần Kaki

- Từ bảng các vật phẩm mới được xác định lại, nhóm thực hiện xây dựng FP-Tree. Với quy ước các vật phẩm như sau: Áo phong - AP, Quần Jean - QJ, Quần Kaki - QK, Mũ lưỡi trai - MLT, Túi xách - TX:



- Sau khi hoàn thành việc xây dựng cây, nhóm tiến hành tạo ra cơ sở mẫu điều kiện (Conditional Pattern Base - CPB). Mục đích là để khởi tạo FP-Tree điều kiện, dựa trên ngưỡng xuất hiện tối thiểu (minSup) trước đó là 2. Tiếp theo, tìm ra các tập phổ biến từ mỗi nhánh (Path) của cây điều kiện vừa được khởi tạo. Với thứ tự duyệt lần lượt là: TX → MLT → QK → QJ → AP:

Vật phẩm	CPB	FP-Tree điều kiện	Mẫu phổ biến
TX	QJ- MLT: 1 AP-QK: 1 AP-QJ-MLT: 1	QJ: 2 MLT: 2 AP: 2	QJ-TX MLT-TX AP-TX QJ-MLT-TX QJ-AP-TX MLT-AP-TX QJ-MLT-AP-TX
MLT	AP-QJ: 1 AP-QK: 1 QJ: 1	AP: 2 QJ: 2	AP-MLT QJ-MLT AP-QJ-MLT
QK	AP: 2 AP-QJ-MLT-TX: 1	AP: 3	AP-QK
QJ	AP: 1	∅	∅
AP	∅	∅	∅

- Từ kết quả trên, nhóm thu được lần lượt các mẫu phổ biến như sau:

Mẫu 1-Itemset	Mẫu 2-Itemset	Mẫu 3-Itemset	Mẫu 4-Itemset
{Áo phong} {Quần Jean} {Quần Kaki} {Mũ lưỡi trai} {Túi xách}	{Áo phong, Túi xách} {Quần Jean, Túi xách} {Mũ lưỡi trai, Túi xách} {Áo phong, Mũ lưỡi trai} {Quần Jean, Mũ lưỡi trai} {Áo phong, Quần Kaki}	{Quần Jean, Mũ lưỡi trai, Túi xách} {Quần Jean, Áo phong, Túi xách} {Mũ lưỡi trai, Áo phong, Túi xách} {Áo phong, Quần Jean, Mũ lưỡi trai}	{Quần Jean, Mũ lưỡi trai, Áo phong, Túi xách}

3. Chọn lọc mẫu

Dựa trên một số tiêu chí nhất định, nhóm có thể lựa chọn những mẫu phổ biến quan trọng và loại bỏ đi những mẫu ít giá trị.

Ví dụ: Nhóm tiến hành lựa chọn các mẫu phổ biến có hơn 2 phần tử. Mục đích của việc này là để xác định liệu những khách hàng mua đồng thời các sản phẩm nằm trong mẫu phổ biến có thể được phân vào các lớp cụ thể hay không?

Mẫu 2-Itemset	Mẫu 3-Itemset	Mẫu 4-Itemset
{Áo phong, Túi xách} {Quần Jean, Túi xách} {Mũ lưỡi trai, Túi xách} {Áo phong, Mũ lưỡi trai} {Quần Jean, Mũ lưỡi trai} {Áo phong, Quần Kaki}	{Quần Jean, Mũ lưỡi trai, Túi xách} {Quần Jean, Áo phong, Túi xách} {Mũ lưỡi trai, Áo phong, Túi xách} {Áo phong, Quần Jean, Mũ lưỡi trai}	{Quần Jean, Mũ lưỡi trai, Áo phong, Túi xách}

4. Chuyển đổi mẫu phổ biến thành dạng đặc trưng

Sau khi đã chọn lọc mẫu phổ biến quan trọng, nhóm cần chuyển đổi những mẫu này thành dạng đặc trưng phù hợp để có thể đưa vào mô hình học máy ở bước 5.

Trong trường hợp này, nhóm sẽ sử dụng One-hot Encoding hoặc Vertical Format để chuyển đổi mẫu phổ biến thành đặc trưng.

Ví dụ: Nhóm sẽ biểu diễn lại các vật phẩm xuất hiện trong mẫu phổ biến ở bước 3 dưới dạng Ma trận Nhị phân (Vertical Format), nhằm phục vụ cho việc phân lớp ở bước tiếp theo. Cụ thể, dữ liệu sẽ được biểu diễn như sau:

STT	AP	QJ	QK	MLT	TX
1	1	0	0	0	1
2	0	1	0	0	1
3	0	0	0	1	1
4	0	1	0	1	1
5	1	1	0	0	1
6	1	0	0	1	1
7	1	1	0	1	1

Ngoài ra để gia tăng hiệu quả cho mô hình phân lớp, nhóm thực hiện tạo thêm các cột kết hợp mẫu phổ biến vừa xác định dựa trên phép toán XOR:

	TX	AP×TX	QJ×TX	MLT×TX	AP×MLT	QJ×MLT	AP×QK	QJ×MLT×TX	QJ×AP×TX	MLT×AP×TX	AP×QJ×MLT	QJ×MLT×AP×TX
...	1	0	1	1	1	0	1	1	0	0	1	0
	1	1	0	1	0	1	0	0	0	1	1	0
	1	1	1	0	1	1	0	0	1	0	1	0
	1	1	0	0	1	0	0	1	0	0	0	1
	1	0	0	1	1	1	1	0	1	0	0	1
	1	0	1	0	0	1	1	0	0	1	0	1
	1	0	0	0	0	0	1	1	1	1	1	0

Từ kết quả thu được, thì bảng dữ liệu hiện tại chưa đủ để thực hiện phân lớp do thiếu nhãn định danh cụ thể. Để khắc phục vấn đề này, nhóm sẽ tiến hành bổ sung nhãn cho bảng dữ liệu. Cụ thể, đối với những mẫu dữ liệu mà có sự xuất hiện đồng

thời của Quần Jean và Túi xách. Những mẫu này sau đó được gán nhãn là “Khách hàng mục tiêu” cho cửa hàng. Trái lại, những mẫu không thỏa mãn điều kiện trên sẽ được gán nhãn là “Không là khách hàng mục tiêu”:

STT	AP	QJ		AP×QJ ×MLT	QJ× MLT× AP×TX	Loại khách hàng
1	1	0	...	1	0	Không là mục tiêu
2	0	1		1	0	Mục tiêu
3	0	0		1	0	Không là mục tiêu
4	0	1		0	1	Mục tiêu
5	1	1		0	1	Mục tiêu
6	1	0		0	1	Không là mục tiêu
7	1	1		1	0	Mục tiêu

Sau khi hoàn tất việc gán nhãn cho mẫu dữ liệu được sử dụng với mục đích dự đoán, bài toán mà nhóm đang tập trung giải quyết đã chuyển thành một bài toán học có giám sát thông thường.

5. Xây dựng mô hình phân lớp

Sử dụng các mẫu phổ biến đã chọn lọc làm đặc trưng để xây dựng mô hình phân lớp. Có thể sử dụng các thuật toán học máy như Naive Bayes, Decision Tree, Random Forest, SVM, Neural Network, ...

Ví dụ: Trong ví dụ này, thay vì sử dụng SVM, nhóm quyết định xây dựng một mô hình cây quyết định (Decision Tree) để phân loại khách hàng dựa trên các đặc trưng phổ biến. Điều này được thực hiện do sự hạn chế về dữ liệu cụ thể để minh họa quá trình phân lớp bằng SVM:


- Vì thời gian hạn chế, ở ví dụ này, nhóm chỉ minh họa cách xây dựng mô hình cây quyết định thông qua hệ số đo duy nhất là Information Gain, nhằm biết được các nút của cây. Với công thức tổng quát như sau (*Tham khảo - TS.Nguyễn An Tế*):

$$Info(D, A) = \sum_{j=1}^v \frac{|D_j^A|}{|D|} \times Entropy(D_j^A)$$

$$Gain(D, A) = Entropy(D) - Info(D, A)$$

Gain(D, AP)	Gain(D, QJ)	Gain(D, QK)	Gain(D, MLT)	Gain(D, TX)	Gain(D, AP×TX)	Gain(D, QJ×TX)	Gain(D, MLT×TX)
0.0202	0.9852	0	0.0202	0.9852	0.0202	0.0202	0.0202
Gain(D, AP×MLT)	Gain(D, QJ×MLT)	Gain(D, AP×QK)	Gain(D, QJ×MLT×TX)	Gain(D, QJ×AP×TX)	Gain(D, MLT×AP×TX)	Gain(D, AP×QJ×MLT)	Gain(D, QJ×MLT×AP×TX)
0.0202	0.0202	0.0202	0.0202	0.0202	0.0202	0.0202	0.0202

- Từ hệ số đo vừa xác định, nhóm cơ bản có thể xác định được ngọn và các đường đi (Path) ban đầu của cây:



6. Sử dụng mô hình

Sau cùng, mô hình phân lớp có thể được sử dụng để phân lớp dữ liệu mới chưa được gán nhãn. Các mẫu phổ biến trong dữ liệu mới sẽ được khai thác và sử dụng làm đặc trưng để dự đoán nhãn của dữ liệu.

Ví dụ: Nếu có một khách hàng mới và biết được hành vi mua hàng của khách hàng đó là {Áo phông, Quần jean, Mũ lưỡi trai}, chúng ta có thể sử dụng mô hình đã xây dựng để dự đoán nhãn cho khách hàng đó.

CHƯƠNG IV. TỔNG QUAN BỘ DỮ LIỆU

1. Sơ lược về bộ dữ liệu

Hotel Reservations Dataset, được đăng tải trên Kaggle bởi Ahsan Raza vào ngày 4 tháng 1 năm 2023, nhằm mục đích phân tích và dự báo khả năng hủy đặt phòng của khách hàng.

Bộ dữ liệu cung cấp thông tin chi tiết về các đơn đặt phòng tại các khách sạn trong khoảng thời gian từ tháng 7 năm 2017 đến tháng 12 năm 2018. Bao gồm 17 thuộc tính, với tổng cộng 36,275 quan sát, và không có giá trị thiếu. Các thuộc tính bao gồm ngày nhận phòng, ngày trả phòng, ngày tạo đặt phòng, cùng với nhiều thông tin khác. Mỗi quan sát đại diện cho một khách hàng đã đặt phòng tại khách sạn.

Bằng cách phân tích và hiểu rõ hơn về các thuộc tính này, nhóm nghiên cứu có thể nắm bắt được hành vi và xu hướng của khách hàng. Điều này giúp nhóm có thể dự đoán chính xác hơn về khả năng hủy đặt phòng thông qua phương pháp phân lớp dựa trên mẫu thường xuyên mà nhóm đã trình bày trước đó.

2. Mô tả thuộc tính của bộ dữ liệu

TÊN THUỘC TÍNH	MÔ TẢ	KIỂU DỮ LIỆU
Booking_ID	Mã đặt phòng	Text
no_of_adults	Số người lớn	Numeric
no_of_children	Số trẻ em	Numeric
no_of_weekend_nights	Số đêm khách đặt vào cuối tuần (Thứ 7, Chủ Nhật)	Numeric
no_of_week_nights	Số đêm khách đặt trong tuần (Thứ 2 - Thứ 5)	Numeric
type_of_meal_plan	Loại bữa ăn khách hàng chọn	Categorical
required_car_parking_space	Nếu khách hàng yêu cầu có bãi đỗ xe thì là '1'; nếu không thì là '0'	Categorical
room_type_reserved	Loại phòng	Categorical
lead_time	Số ngày giữa ngày đặt phòng và ngày đến	Numeric
arrival_date	Ngày đến	Datetime
market_segment_type	Hình thức tiếp cận của khách hàng	Categorical
repeated_guest	Nếu là khách hàng cũ thì là '1'; nếu là khách hàng mới thì là '0'	Categorical

no_of_previous_cancellations	Số lần khách hàng hủy đặt phòng trước đây	Numeric
no_of_previous_bookings_not_canceled	Số lần khách hàng không hủy đặt phòng trước đây	Numeric
avg_price_per_room	Giá phòng bình quân theo ngày	Numeric
no_of_special_requests	Tổng số yêu cầu đặc biệt khác (ở tầng cao, tầm nhìn đẹp)	Numeric
booking_status	Đơn đặt phòng bị hủy hoặc không	Categorical

3. Tiền xử lý dữ liệu

a. Thăm dò dữ liệu

Đầu tiên, nhóm sẽ tiến hành thăm dò dữ liệu (data exploration) để nắm được những thông tin cơ bản như số lượng thuộc tính (cột), bản ghi (dòng) được ghi nhận trong bộ dữ liệu. Qua đó, giúp nhóm có thể xác định được quy mô cũng như các thông tin quan trọng của bộ dữ liệu mà nhóm sẽ cần quan tâm đến.

Kích thước của bộ dữ liệu gồm 36275 dòng và 19 cột.

```

RangeIndex: 36275 entries, 0 to 36274
Data columns (total 19 columns):
 #   Column                                Non-Null Count  Dtype
---  -
 0   Booking_ID                           36275 non-null  object
 1   no_of_adults                         36275 non-null  int64
 2   no_of_children                       36275 non-null  int64
 3   no_of_weekend_nights                 36275 non-null  int64
 4   no_of_week_nights                   36275 non-null  int64
 5   type_of_meal_plan                    36275 non-null  object
 6   required_car_parking_space           36275 non-null  int64
 7   room_type_reserved                   36275 non-null  object
 8   lead_time                           36275 non-null  int64
 9   arrival_year                         36275 non-null  int64
10  arrival_month                       36275 non-null  int64
11  arrival_date                        36275 non-null  int64
12  market_segment_type                 36275 non-null  object
13  repeated_guest                      36275 non-null  int64
14  no_of_previous_cancellations         36275 non-null  int64
15  no_of_previous_bookings_not_canceled 36275 non-null  int64
16  avg_price_per_room                   36275 non-null  float64
17  no_of_special_requests               36275 non-null  int64
18  booking_status                      36275 non-null  object
dtypes: float64(1), int64(13), object(5)
memory usage: 5.3+ MB

```

Qua việc tìm hiểu sơ lược bộ dữ liệu, nhóm có thể thu được các thông tin cơ bản như sau: bộ dữ liệu gồm 19 cột và 36.275 dòng.

Ngoài ra, để có thể nắm bắt thêm các thông tin cụ thể hơn về bộ dữ liệu, nhóm sẽ tiến hành quan sát số giá trị duy nhất của mỗi thuộc tính.

```
Booking_ID          36275
no_of_adults         5
no_of_children       6
no_of_weekend_nights 8
no_of_week_nights    18
type_of_meal_plan     4
required_car_parking_space 2
room_type_reserved    7
lead_time            352
arrival_year          2
arrival_month        12
arrival_date         31
market_segment_type   5
repeated_guest        2
no_of_previous_cancellations 9
no_of_previous_bookings_not_canceled 59
avg_price_per_room    3930
no_of_special_requests 6
booking_status        2
dtype: int64
```

Bằng việc tìm hiểu về các giá trị duy nhất của mỗi thuộc tính, nhóm đã có thể đưa ra nhận xét rằng: Đa số các biến định danh đều mang số giá trị riêng biệt tương đối ít. Ngược lại với các biến định lượng là ‘**lead_time**’ và ‘**avg_price_per_room**’ có rất nhiều giá trị. Điều này sẽ có thể gây khó khăn cho nhóm trong quá trình phân tích dữ liệu về sau.

Sau khi đã có hiểu biết cơ bản về bộ dữ liệu, giờ đây nhóm sẽ thực hiện một vài thao tác như loại bỏ các thuộc tính không cần thiết, và chỉnh dạng dữ liệu của một số thuộc tính để giúp bộ dữ liệu trở nên phù hợp hơn cho việc phân tích và xây dựng các mô hình phân lớp.

Ở đây, nhóm sẽ loại bỏ cột ‘**Booking_ID**’ khỏi bộ dữ liệu vì đây chỉ là thuộc tính chỉ mã đặt phòng nên ta không cần quan tâm đến.

```
# Loại bỏ cột Booking_ID
df = df.drop(columns = ['Booking_ID'])
```

Tiếp theo đó, nhóm cũng sẽ chuyển kiểu dữ liệu hai biến ‘**repeated_guest**’ và ‘**required_car_parking_space**’ mang giá trị {0, 1}, từ biến định lượng sang biến định danh để thuận tiện cho quá trình phân lớp bộ dữ liệu.

```
# Chuyển kiểu cột dữ liệu
df['repeated_guest'] = df['repeated_guest'].astype(object)
df['required_car_parking_space'] = df['required_car_parking_space'].astype(object)
```

b. Làm sạch dữ liệu

Đây được xem là một trong những bước quan trọng nhất trong quá trình tiền xử lý dữ liệu. Bước này giúp nhóm có thể phát hiện các giá trị bị thiếu (missing values) và các giá trị bất thường/ nhiễu (noisy values) và xử lý chúng. Bước này giúp bộ dữ liệu đảm bảo tính nhất quán và chắc chắn rằng không có sự thiếu hụt về thông tin. Từ đó, nhóm có thể sử dụng bộ dữ liệu này và tiến hành phân tích ở các bước tiếp theo với độ tin cậy cao.

- **Kiểm tra giá trị bị thiếu**

```
no_of_adults          0
no_of_children        0
no_of_weekend_nights  0
no_of_week_nights     0
type_of_meal_plan     0
required_car_parking_space 0
room_type_reserved    0
lead_time             0
arrival_year          0
arrival_month         0
arrival_date          0
market_segment_type   0
repeated_guest        0
no_of_previous_cancellations 0
no_of_previous_bookings_not_canceled 0
avg_price_per_room    0
no_of_special_requests 0
dtype: int64
```

Sau khi tiến hành kiểm tra các giá trị bị thiếu, nhóm nhận thấy rằng trong các cột không có giá trị nào bị thiếu nên không cần phải xử lý bước này.

- **Kiểm tra giá trị nhiễu**

Đầu tiên, nhóm sẽ tiến hành kiểm tra nhiễu ở tất cả các biến định lượng. Ở phần này, nhóm sẽ sử dụng quy tắc 3-sigma để tìm ra các outlier của từng cột một. Outlier được xem là những giá trị nằm ngoài khoảng ba độ lệch chuẩn. Do vậy, nhóm sẽ tính toán các giới hạn trên/ dưới so với giá trị trung bình cho từng biến.

```
# Sử dụng hàm để kiểm tra outlier cho tất cả các cột trong DataFrame
def check_outliers_using_3_sigma(df):
    has_outliers = True
    while has_outliers:
        has_outliers = False
        for col in df.columns:
            if df[col].dtype in ['int64', 'float64']:
                lech3sigma_tren = round(df[col].mean() + 3 * df[col].std(ddof=1))
                lech3sigma_duoi = round(df[col].mean() - 3 * df[col].std(ddof=1))
                df_filter = df[(df[col] > lech3sigma_tren) | (df[col] < lech3sigma_duoi)]

                if df_filter[col].count() > 0:
                    print(f'Cột {col} có {df_filter[col].count()} giá trị nhiều là các giá trị ngoài khoảng ({lech3sigma_duoi}, {lech3sigma_tren})')
                    # Thay thế nhiều bằng trung vị
                    trungvi = df[col].median()
                    df.loc[(df[col] > lech3sigma_tren) | (df[col] < lech3sigma_duoi), col] = trungvi
                    has_outliers = True
                else:
                    print(f'Cột {col}: Không có outlier.')

# Gọi hàm trên DataFrame df
check_outliers_using_3_sigma(df)
```

Sau khi đã tính toán xong các giá trị trên, nhóm sẽ tiến hành so sánh giá trị của mỗi phần tử trong cột với giới hạn trên/ dưới tương ứng. Nếu giá trị nằm ngoài khoảng này, nó sẽ được xem là ngoại lệ và được in ra theo danh sách như sau:

```
Cột no_of_adults có 16 giá trị nhiều là các giá trị ngoài khoảng (0, 3)
Cột no_of_children có 1080 giá trị nhiều là các giá trị ngoài khoảng (-1, 1)
Cột no_of_weekend_nights có 184 giá trị nhiều là các giá trị ngoài khoảng (-2, 3)
Cột no_of_week_nights có 324 giá trị nhiều là các giá trị ngoài khoảng (-2, 6)
Cột lead_time có 376 giá trị nhiều là các giá trị ngoài khoảng (-173, 343)
Cột arrival_year: Không có outlier.
Cột arrival_month: Không có outlier.
Cột arrival_date: Không có outlier.
Cột no_of_previous_cancellations có 140 giá trị nhiều là các giá trị ngoài khoảng (-1, 1)
Cột no_of_previous_bookings_not_canceled có 267 giá trị nhiều là các giá trị ngoài khoảng (-5, 5)
Cột avg_price_per_room có 353 giá trị nhiều là các giá trị ngoài khoảng (-2, 209)
Cột no_of_special_requests có 86 giá trị nhiều là các giá trị ngoài khoảng (-2, 3)
```

Sau khi tiến hành kiểm tra các giá trị bất thường của các biến có kiểu dữ liệu số, nhóm nhận thấy rằng hầu hết các biến đều có các giá trị bất thường. Do vậy, nhóm sẽ tiến hành xử lý những giá trị này bằng cách thay thế chúng bằng trung vị thay vì xóa chúng đi vì muốn đảm bảo sự đầy đủ và tránh làm mất đi thông tin ban đầu của bộ dữ liệu.

```
Cột no_of_adults: Không có outlier.
Cột no_of_children: Không có outlier.
Cột no_of_weekend_nights: Không có outlier.
Cột no_of_week_nights: Không có outlier.
Cột lead_time: Không có outlier.
Cột arrival_year: Không có outlier.
Cột arrival_month: Không có outlier.
Cột arrival_date: Không có outlier.
Cột no_of_previous_cancellations: Không có outlier.
Cột no_of_previous_bookings_not_canceled: Không có outlier.
Cột avg_price_per_room: Không có outlier.
Cột no_of_special_requests: Không có outlier.
```

Sau khi xử lý, tất cả các biến đều đã không còn giá bất thường nào

c. Rời rạc hóa dữ liệu

Như đã tìm hiểu thông tin về bộ dữ liệu ở trên, nhóm đã biết được rằng bộ dữ liệu có chứa vài thuộc tính có kiểu dữ liệu là số (liên tục) như **'lead_time'** và **'avg_price_per_room'**, và một vài thuộc tính khác cũng mang kiểu dữ liệu số (rời rạc) như **'no_of_adults'**, **'no_of_children'**, **'no_of_special_requests'**....

Do đó, để chuẩn bị cho quá trình phân lớp dữ liệu ở chương sau, ở phần này nhóm sẽ tiến hành rời rạc hóa các biến này.

```
# Rời rạc các biến lead_time và avg_price_per_room
df['lead_time_group'] = pd.qcut(df['lead_time'], 4)
df['avg_price_per_room_group'] = pd.qcut(df['avg_price_per_room'], 4)
df = df.drop(columns = ['lead_time', 'avg_price_per_room'])
```

Đầu tiên, nhóm sẽ xử lý các biến liên tục trước bằng cách tạo ra một cột mới có tên là **'lead_time_group'**, trong đó giá trị của mỗi dòng được xác định dựa trên phân vị (quantile) của cột **'lead_time'** thành 4 khoảng (quartiles). Cụ thể, giá trị của cột mới sẽ là nhóm của giá trị trong cột **'lead_time'** sao cho mỗi nhóm có số lượng gần bằng nhau. Tương tự như trên, tạo ra một cột mới có tên là **'avg_price_per_room_group'**, trong đó giá trị của mỗi dòng được xác định dựa trên phân vị của cột **'avg_price_per_room'** thành 4 khoảng.

Sau khi đã xử lý các biến liên tục, nhóm sẽ tiếp tục xử lý các biến rời rạc. Đối với các biến này nhóm sẽ không áp dụng như cách trên. Mà thay vào đó, nhóm sẽ thay đổi giá trị ở các biến này thành dạng **'tên biến + giá trị ô tương ứng'**.

```
columns_to_exclude = ['type_of_meal_plan', 'room_type_reserved', 'market_segment_type']
# Chuyển giá trị ở các ô thành dạng "tên cột (giá trị ở ô tương ứng)" cho các cột trừ các cột có giá trị số rời rạc và nhị phân
df = df.apply(lambda x: x.astype(str).map(lambda y: f'{x.name} ({y})') if x.name not in columns_to_exclude else x)
```

Sau quá trình tiền xử lý, bộ dữ liệu còn 17 cột và 36.275 dòng, không có thay đổi gì về số lượng thuộc tính và bản ghi so với ban đầu. Tuy nhiên, về bản chất các thuộc tính đã có một số thay đổi về hình dạng dữ liệu như sau:


```
no_of_adults      object
no_of_children    object
no_of_weekend_nights  object
no_of_week_nights  object
type_of_meal_plan  object
required_car_parking_space  object
room_type_reserved  object
arrival_year      object
arrival_month      object
arrival_date       object
market_segment_type  object
repeated_guest     object
no_of_previous_cancellations  object
no_of_previous_bookings_not_canceled  object
no_of_special_requests  object
lead_time_group    object
avg_price_per_room_group  object
dtype: object
```

Qua kết quả trên, nhóm có thể đưa ra nhận xét rằng, tất cả các thuộc tính đều có kiểu dữ liệu là object (biến định danh). Điều này sẽ giúp cho quá trình phân lớp trở nên dễ dàng hơn và mang lại kết quả phân lớp chính xác hơn.

CHƯƠNG V. ỨNG DỤNG GIẢI THUẬT TRÊN BỘ DỮ LIỆU

- **Mã nguồn:** [Classification using Frequent Patterns.ipynb](#)

1. Chuẩn bị dữ liệu

Đầu tiên, nhóm nghiên cứu sẽ tiến hành biến đổi bộ dữ liệu đã được tiền xử lý về dạng crosstab hoặc transaction để phù hợp với quá trình khai thác mẫu. Để có thể đưa bộ dữ liệu về dạng crosstab, nhóm cần phải biến đổi dataframe ban đầu bằng cách áp dụng OneHotEncoder để mã hóa các cột trong dataframe. Tên của các cột mới trong dataframe này chính là giá trị của các cột ban đầu. Sau khi đã loại bỏ các cột ban đầu và thay thế bằng các cột mới được mã hóa, nhóm sẽ có được một bảng dữ liệu có dạng crosstab như sau:

	no_of_adults (2)	no_of_adults (1)	no_of_adults (3)	no_of_adults (0)	no_of_children (0)	no_of_children (1)	no_of_weekend_nights (1)	no_of_weekend_nights (2)	no_of_weekend_nights (0)	no_of_weekend_nights (3)	...
0	False	False	True	False	True	False	False	True	False	False	...
1	False	False	True	False	True	False	False	False	True	False	...
2	False	True	False	False	True	False	False	False	True	False	...
3	False	False	True	False	True	False	True	False	False	False	...
4	False	False	True	False	True	False	False	True	False	False	...
...
36270	False	False	False	True	True	False	False	False	True	False	...
36271	False	False	True	False	True	False	False	True	False	False	...
36272	False	False	True	False	True	False	False	False	True	False	...
36273	False	False	True	False	True	False	True	False	False	False	...
36274	False	False	True	False	True	False	False	True	False	False	...

36275 rows x 96 columns

Bộ dữ liệu ban đầu:

	no_of_adults	no_of_children	no_of_weekend_nights	no_of_week_nights	type_of_meal_plan	required_car_parking_space
0	no_of_adults (2)	no_of_children (0)	no_of_weekend_nights (1)	no_of_week_nights (2)	Meal Plan 1	required_car_parking_space (0)
1	no_of_adults (2)	no_of_children (0)	no_of_weekend_nights (2)	no_of_week_nights (3)	Not Selected	required_car_parking_space (0)
2	no_of_adults (1)	no_of_children (0)	no_of_weekend_nights (2)	no_of_week_nights (1)	Meal Plan 1	required_car_parking_space (0)
3	no_of_adults (2)	no_of_children (0)	no_of_weekend_nights (0)	no_of_week_nights (2)	Meal Plan 1	required_car_parking_space (0)
4	no_of_adults (2)	no_of_children (0)	no_of_weekend_nights (1)	no_of_week_nights (1)	Not Selected	required_car_parking_space (0)

Trong các bước tiếp theo, nhóm sẽ xây dựng giải thuật dựa trên bảng dữ liệu sau đây:

	Items	booking_status
0	[no_of_adults (3), no_of_children (0), no_of_w...	Not_Canceled
1	[no_of_adults (3), no_of_children (0), no_of_w...	Not_Canceled
2	[no_of_adults (1), no_of_children (0), no_of_w...	Canceled
3	[no_of_adults (3), no_of_children (0), no_of_w...	Canceled
4	[no_of_adults (3), no_of_children (0), no_of_w...	Canceled
...
36270	[no_of_adults (0), no_of_children (0), no_of_w...	Not_Canceled
36271	[no_of_adults (3), no_of_children (0), no_of_w...	Canceled
36272	[no_of_adults (3), no_of_children (0), no_of_w...	Not_Canceled
36273	[no_of_adults (3), no_of_children (0), no_of_w...	Canceled
36274	[no_of_adults (3), no_of_children (0), no_of_w...	Not_Canceled
36275 rows x 2 columns		

Bảng dữ liệu trên có hai cột, cột đầu tiên là ‘**Items**’, là tập hợp các giá trị của mỗi dòng dữ liệu ở bộ dữ liệu gốc. Cột thứ hai là ‘**booking_status**’, là mục tiêu trong bài toán phân loại của nhóm, và có hai nhãn là {**Not_Canceled**, **Canceled**}.

2. Khai thác mẫu phổ biến và chọn lọc mẫu

Để tìm ra các mẫu phổ biến từ dữ liệu đã chuẩn bị ban đầu, ở đây nhóm sẽ sử dụng thuật toán khai thác mẫu phổ biến FP-Growth, với ngưỡng hỗ trợ (**min_sup**) - ngưỡng tối thiểu để một mẫu được xem là phổ biến là **0.5**.

Đầu tiên, nhóm sẽ áp dụng thuật toán FP-Growth để tìm ra các mẫu phổ biến trong dataframe. Các mẫu phổ biến này sẽ được lưu trữ trong ‘**frequent_patterns**’. Sau đó, nhóm sẽ tính toán số lần xuất hiện của mỗi item và sắp xếp chúng theo thứ tự giảm dần rồi so sánh với min_sup. Nếu các mẫu có chỉ số support lớn hơn so với min_sup, mẫu đó sẽ được đưa vào danh sách mẫu phổ biến.

```
frequent_patterns = fpgrowth(df, min_support = 0.5, use_colnames=True)
frequent_patterns['itemsets'] = frequent_patterns['itemsets'].apply(lambda x: ', '.join(x))

# Sắp xếp chỉ số dựa trên số lượng từ
word_counts = frequent_patterns['itemsets'].str.split(",").apply(len)
sorted_indices = np.argsort(word_counts)

# Sắp xếp lại cột "Itemsets" dựa trên chỉ số đã sắp xếp
frequent_patterns['itemsets'] = frequent_patterns['itemsets'].iloc[sorted_indices].values

# Lưu các tập phổ biến lớn nhất
frequent_patterns_filter = frequent_patterns.copy()
frequent_patterns_reverse = frequent_patterns.iloc[::-1]
for valuehigh in frequent_patterns_reverse['itemsets']:
    for valuelow in frequent_patterns['itemsets']:
        dem = 0
        if len(valuelow.split(', ')) == len(valuehigh.split(', ')):
            break
        for l in valuelow.split(', '):
            if l in valuehigh.split(', '):
                dem = dem + 1
        if dem == len(valuelow.split(', ')):
            frequent_patterns_filter = frequent_patterns_filter[frequent_patterns['itemsets'] != valuelow]
```

Sau đây là bảng dữ liệu chứa các mẫu phổ biến mà nhóm đã tìm được:

	support	itemsets
0	1.000000	no_of_previous_bookings_not_canceled (0)
1	1.000000	Complementary
2	0.974363	arrival_year (2018)
3	0.969014	no_of_adults (3)
4	0.955396	Meal Plan 1
...
422	0.502329	required_car_parking_space (0), Meal Plan 1, n...
423	0.504121	required_car_parking_space (0), no_of_previous...
424	0.502329	required_car_parking_space (0), no_of_previous...
425	0.502329	required_car_parking_space (0), no_of_previous...
426	0.502329	required_car_parking_space (0), no_of_previous...
427 rows x 2 columns		

Để có thể chọn lọc mẫu từ các mẫu phổ biến đã tìm được, nhóm sẽ dùng vòng lặp để so sánh các tập itemsets và lọc bỏ các itemsets mà có số lượng phần tử nhỏ hơn các itemsets có số phần tử nhiều nhất. Nếu một itemsets có số phần tử ít hơn, và tất cả các phần tử của nó đều thuộc về itemsets có số phần tử nhiều nhất, thì itemsets đó sẽ bị loại bỏ khỏi danh sách mẫu phổ biến.

	support	itemsets
410	0.537092	required_car_parking_space (0), no_of_previous...
411	0.537092	required_car_parking_space (0), Meal Plan 1, n...
417	0.520276	Meal Plan 1, no_of_previous_bookings_not_cance...
418	0.520276	required_car_parking_space (0), Meal Plan 1, n...
421	0.504121	required_car_parking_space (0), Meal Plan 1, n...
422	0.502329	required_car_parking_space (0), Meal Plan 1, n...
423	0.504121	required_car_parking_space (0), no_of_previous...
424	0.502329	required_car_parking_space (0), no_of_previous...
425	0.502329	required_car_parking_space (0), no_of_previous...
426	0.502329	required_car_parking_space (0), no_of_previous...

3. Chuyển đổi mẫu phổ biến thành dạng đặc trưng

Sau khi đã chọn lọc mẫu từ các mẫu phổ biến, nhóm cần chuyển đổi những mẫu này thành các đặc trưng phù hợp để có thể đưa vào mô hình học máy.

Ngoài ra để có thể áp dụng các mẫu được chọn lọc cho mô hình phân lớp, nhóm sẽ kết hợp mẫu phổ biến vừa xác định dựa trên phép toán **XOR**.

```
# Lấy các cột là mẫu phổ biến
df_filtered = df[df.columns[df.columns.isin(frequent_patterns.itemsets)]]

## XOR của các tập phổ biến
for item in frequent_patterns_filter['itemsets']:
    row = []
    value = []
    for index in item.split(', '):
        row.append(index)
    name = 'x '.join(row)

    for i in row:
        value.append(df_filtered[i])

    result = value[0]
    for i in range(1, len(value)):
        result = [x ^ y for x, y in zip(result, value[i])]

    df_filtered[name] = result

# Xây dựng đặc trưng
features = df.astype(int).values
```

Sau khi hoàn tất việc gán nhãn cho mẫu dữ liệu được sử dụng với mục đích dự đoán, bài toán mà nhóm đang tập trung giải quyết đã chuyển thành một bài toán học có giám sát thông thường.

required_car_parking_space (0) x Meal Plan 1 x no_of_previous_bookings_not_canceled (0) x repeated_guest (0) x no_of_adults (3) x no_of_previous_cancellations (0)	required_car_parking_space (0) x Meal Plan 1 x no_of_previous_bookings_not_canceled (0) x Room_Type 1 x repeated_guest (0) x no_of_previous_cancellations (0) x no_of_children (0)	required_car_parking_space (0) x Meal Plan 1 x no_of_previous_bookings_not_canceled (0) x Room_Type 1 x no_of_previous_cancellations (0) x no_of_children (0)	required_car_parking_space (0) x Meal Plan 1 x no_of_previous_bookings_not_canceled (0) x repeated_guest (0) x no_of_previous_cancellations (0) x Room_Type 1	required_car_parking_space (0) x Meal Plan 1 x no_of_previous_bookings_not_canceled (0) x repeated_guest (0) x arrival_year (2018) x no_of_previous_cancellations (0) x no_of_children (0)
...	False	False	False	False
...	True	True	True	False
...	True	False	False	True
...	False	False	False	True
...	True	True	True	False
...
...	True	True	True	True
...	False	False	False	True
...	False	False	False	True
...	True	True	True	False
...	False	False	False	True

required_car_parking_space (0) x no_of_previous_bookings_not_canceled (0) x repeated_guest (0) x arrival_year (2018) x no_of_adults (3) x no_of_previous_cancellations (0) x no_of_children (0)	required_car_parking_space (0) x no_of_previous_bookings_not_canceled (0) x Room_Type 1 x repeated_guest (0) x no_of_adults (3) x no_of_previous_cancellations (0) x no_of_children (0)	required_car_parking_space (0) x no_of_previous_bookings_not_canceled (0) x Room_Type 1 x repeated_guest (0) x arrival_year (2018) x no_of_previous_cancellations (0) x no_of_children (0)	required_car_parking_space (0) x no_of_previous_bookings_not_canceled (0) x repeated_guest (0) x arrival_year (2018) x no_of_previous_cancellations (0) x complementary x no_of_children (0)	booking_status
False	True	False	True	Not_Canceled
True	True	True	True	Not_Canceled
False	False	True	True	Canceled
True	True	True	True	Canceled
True	True	True	True	Canceled
...
False	True	False	True	Not_Canceled
True	True	True	True	Canceled
True	True	True	True	Not_Canceled
True	True	True	True	Canceled
True	True	True	False	Not_Canceled

4. Xây dựng mô hình phân lớp

Đầu tiên nhóm sẽ gán giá trị cần dự đoán là biến target '**booking_status**'. Tiếp sau đó, nhóm cần tiến hành chia dữ liệu thành hai phần là tập dữ liệu và tập huấn luyện với tỉ lệ chia là 0.2, 80% bộ dữ liệu ban đầu sẽ được huấn luyện để dự đoán 20% dữ liệu còn lại.

```
y = train['booking_status']
X = train.drop(columns = 'booking_status')

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = .2, random_state = 1)
```

Để xây dựng mô hình phân lớp, nhóm sử dụng thuật toán SVM (Support Vector Machine), vì SVM làm việc hiệu quả với bộ dữ liệu có số lượng đầu vào cao. Ngoài ra, SVM còn có khả năng kiểm soát hiệu quả và hạn chế tình trạng quá khớp (overfitting).

```
##-----
## Xây dựng mô hình
##-----
model = svm.SVC(kernel = 'linear')
model.fit(X_train, y_train)
```

▼ SVC
SVC(kernel='linear')

5. Sử dụng mô hình

Sau khi đã huấn luyện mô hình thành công, nhóm sẽ dùng mô hình này để dự đoán kết quả.

```
# Dự đoán nhãn lớp cho tập kiểm tra
y_pred = model.predict(X_test)

result_df = pd.DataFrame({'Actual': y_test, 'Predicted': y_pred})
result_df
```

So sánh kết quả thực tế và kết quả dự đoán:

	Actual	Predicted
30392	Not_Canceled	Canceled
6685	Canceled	Not_Canceled
8369	Not_Canceled	Canceled
2055	Not_Canceled	Not_Canceled
10969	Canceled	Not_Canceled
...
32859	Canceled	Not_Canceled
35405	Not_Canceled	Not_Canceled
36098	Not_Canceled	Not_Canceled
34412	Not_Canceled	Not_Canceled
8034	Not_Canceled	Not_Canceled

7255 rows × 2 columns

CHƯƠNG VI. ĐÁNH GIÁ

1. Đánh giá mô hình

Trong các bài toán phân loại, accuracy (độ chính xác) thường được sử dụng để đánh giá hiệu suất của mô hình. Độ chính xác được tính bằng tỉ lệ giữa số lượng dự đoán đúng và tổng số mẫu trong tập kiểm tra. Độ chính xác càng cao đồng nghĩa với việc mô hình có khả năng dự đoán đúng cao trên tập kiểm tra.

Ngoài ra, nhóm còn có một công cụ khác để đánh giá hiệu suất của mô hình phân lớp, đó chính là ma trận nhầm lẫn (confusion matrix). Nó thể hiện sự so sánh giữa dự đoán của mô hình và giá trị thực tế của dữ liệu.

```
Accuracy: 0.74  
Confusion matrix:  
[[1041 1307]  
 [ 587 4320]]
```

Qua kết quả trên, nhóm đã có thể đưa ra các nhận xét như sau:

- Với độ chính xác là **74%**, nhóm có thể kết luận rằng mô hình trên có khả năng phân lớp đúng đối với một phần dữ liệu lớn. Tuy nhiên, để có thể đưa ra nhận xét chính xác hơn, nhóm có thể xem xét đến các thành phần khác của ma trận nhầm lẫn.
- Ma trận nhầm lẫn:
 - **True Positives (TP)** - số lượng mô hình dự đoán đúng thuộc lớp dương: 4320
 - **True Negatives (TN)** - số lượng mô hình dự đoán đúng không thuộc lớp dương: 1041
 - **False Positives (FP)** - số lượng mô hình dự đoán sai thuộc lớp dương, trong khi là không thuộc: 1307
 - **False Negatives (FN)** - số lượng mô hình dự đoán sai không thuộc lớp dương, trong khi là: 587

2. So sánh độ chính xác của mô hình phân lớp giữa tập dữ liệu sử dụng mẫu thường xuyên và không sử dụng mẫu thường xuyên

```
Accuracy: 0.68
Confusion matrix:
[[ 0 2348]
 [ 0 4907]]
```

Qua kết quả trên, nhóm đã có thể đưa ra các nhận xét như sau:

- Với độ chính xác là **68%**, nhóm có thể kết luận rằng mô hình trên có khả năng phân lớp tương đối đúng đối với một phần dữ liệu lớn. Tuy nhiên, để có thể đưa ra nhận xét chính xác hơn, ta có thể xem xét đến các thành phần khác của ma trận nhầm lẫn.
- Ma trận nhầm lẫn:
 - **True Positives (TP)** - số lượng mô hình dự đoán đúng thuộc lớp dương: 4907
 - **True Negatives (TN)** - số lượng mô hình dự đoán đúng không thuộc lớp dương: 0
 - **False Positives (FP)** - số lượng mô hình dự đoán sai thuộc lớp dương, trong khi là không thuộc: 2348
 - **False Negatives (FN)** - số lượng mô hình dự đoán sai không thuộc lớp dương, trong khi là: 0

Mặc dù, mô hình phân lớp với tập dữ liệu không sử dụng mẫu thường xuyên có độ chính xác tương đối là thấp hơn so với tập dữ liệu có sử dụng mẫu thường xuyên (68% và 74%). Tuy nhiên, khi so sánh với ma trận nhầm lẫn, ta nhận thấy là giá trị TN và FN đều bằng 0.

Điều đó có thể cho thấy rằng: Phương pháp phân loại dựa trên mẫu phổ biến và phương pháp phân loại thông thường là hai phương pháp có những yêu cầu về bộ dữ liệu khác nhau.

Nếu dữ liệu có tính chất phổ biến và quan trọng là tìm hiểu mẫu xuất hiện thường xuyên, phân loại dựa trên mẫu phổ biến có thể được xem xét. Đối với dữ liệu phức tạp và đa dạng, phân loại thông thường thường là lựa chọn phù hợp. Phân loại thông thường thường đạt hiệu suất tốt trên nhiều loại bài toán. Phân loại dựa trên mẫu phổ biến có thể hiệu quả trong các tình huống cụ thể.

Lựa chọn giữa phân loại dựa trên mẫu phổ biến và phân loại thông thường phụ thuộc vào đặc tính cụ thể của dữ liệu và mục tiêu của bài toán phân loại.

CHƯƠNG VII. KẾT LUẬN

Sau khi thực hiện dự án nghiên cứu về: "**Ứng dụng phương pháp phân lớp dựa trên mẫu thường xuyên để dự đoán khả năng hủy đặt phòng của khách hàng**", nhóm nghiên cứu đã tiến hành phân tích và triển khai phương pháp lấy mẫu thường xuyên để làm cơ sở thực hiện phân loại khách hàng. Mục tiêu là dự đoán khả năng hủy đặt phòng của họ, từ đó mang lại chiến lược chi tiết giúp doanh nghiệp hiểu sâu hơn về những tình huống cụ thể dẫn đến quyết định này từ phía khách hàng. Nhờ vào quá trình này, không chỉ có thể cải thiện trải nghiệm của khách hàng mà còn tăng cường sự tương tác trong quá trình họ sử dụng dịch vụ hoặc liên lạc với doanh nghiệp.

Đặc điểm nổi bật:

Trong bài nghiên cứu, nhóm đã áp dụng đa các phương pháp, bao gồm: lựa chọn mẫu phổ biến thích hợp, sau đó mới thực hiện phân lớp để đạt được hiệu quả cao nhất. Thông qua phương pháp này, nhóm có thể xác định các tập mục quan trọng trong dữ liệu khách hàng, điều này giúp nhóm hiểu rõ hơn về xu hướng có thể xảy ra, cũng như mối quan hệ giữa các mục trong dữ liệu, từ đó cung cấp thông tin quan trọng để phân loại khách hàng. Hơn nữa, việc lựa chọn và áp dụng các phương pháp phân lớp phù hợp giúp nhóm đạt được kết quả phân loại chính xác và hiệu quả. Điều này giúp tối ưu hóa quy trình tính toán và sử dụng các kỹ thuật song song để gia tăng tốc độ xử lý.

Về mặt thuận lợi:

- **Xác định mẫu phổ biến:** Phương pháp này giúp phân tích và nhận biết các mẫu phổ biến trong dữ liệu khách hàng, giúp hiểu sâu hơn về hành vi lựa chọn của họ, hỗ trợ đưa ra dự đoán về khả năng xảy ra rủi ro của doanh nghiệp đối với việc hủy đặt phòng.
- **Tính linh hoạt và đa dạng:** Giải thuật này có khả năng xử lý đa dạng và linh hoạt các thuộc tính và đặc điểm của khách hàng. Nó có thể được áp dụng cho nhiều lĩnh vực nhà hàng - khách sạn khác nhau, từ đó có thể điều chỉnh mô hình để phù hợp với yêu cầu cụ thể của từng đối tượng khách hàng.
- **Độ chính xác cao:** Phương pháp này dự đoán nhãn sản phẩm với độ chính xác cao. Bằng cách sử dụng các mẫu phổ biến có sẵn trong dữ liệu, mô hình tìm ra sự tương đồng và liên quan giữa hành vi của khách hàng để đưa ra dự đoán chính xác về khả năng đặt phòng của họ.

Về mặt hạn chế:

- **Độ phức tạp tính toán:** Phương pháp này có thể đòi hỏi tính toán phức tạp, đặc biệt khi xử lý tập dữ liệu lớn và phức tạp. Việc tìm kiếm và xác định mẫu phổ biến có thể tốn thời gian và tài nguyên tính toán.

- **Xử lý dữ liệu không đồng nhất:** Dữ liệu trong bộ dữ liệu thường phức tạp và không đồng nhất. Các hành vi có thể có nhiều thuộc tính và đặc điểm khác nhau, và việc đối phó với sự không đồng nhất này có thể ảnh hưởng đến hiệu suất của phương pháp.
- **Thiếu kinh nghiệm thực tế:** Vì nhóm hiện đang là sinh viên, do đó chưa có nhiều kinh nghiệm trong lĩnh vực phân tích dữ liệu trong ngành nhà hàng - khách sạn. Trong quá trình thực hiện đề tài, nhóm đã tham khảo nhiều tài liệu từ các nguồn bên ngoài để giải quyết bài toán. Do đó, chúng em không thể hoàn toàn đảm bảo tính chính xác của kết quả nghiên cứu.

Kinh nghiệm đạt được:

Đầu tiên, nhóm nhận thấy, việc đánh giá các phương pháp là rất quan trọng để đảm bảo tính chính xác và khả năng áp dụng của nghiên cứu. Nhóm đã sử dụng các phương pháp đo lường hiệu suất như độ hỗ trợ của mô hình để đánh giá kết quả và cải thiện phương pháp nghiên cứu.

Thứ hai, trong quá trình làm việc với dữ liệu nhà hàng - khách sạn, nhóm cũng nhận thấy rằng, dữ liệu thường rất phức tạp và không đồng nhất. Vì vậy, nhóm đã phải làm sạch dữ liệu, xử lý giá trị thiếu và đảm bảo tính toàn vẹn và chính xác của kết quả phân loại và dự đoán.

Và cuối cùng, khi triển khai các phương pháp phân lớp trên bộ dữ liệu, nhóm nhận thấy rằng tính khả thi và hiệu suất tính toán là rất quan trọng. Vì vậy, nhóm đã phải đảm bảo rằng phương pháp của nhóm phải có tính khả thi và hiệu suất tính toán đủ cao để áp dụng cho dữ liệu lớn và đáp ứng được yêu cầu thời gian thực.

PHỤ LỤC

1. Mã nguồn

- Link Github: [Neyung/NAT_ML_GROUP6 \(github.com\)](#)
- Ứng dụng vào bộ dữ liệu: [Classification using Frequent Patterns.ipynb](#)

2. Bảng phân công

THÀNH VIÊN	PHÂN CÔNG	ĐÁNH GIÁ
Võ Minh Nguyên	Tìm hiểu thuật toán, Viết các bước xây dựng thuật toán, Tổng hợp nội dung báo cáo	100%
Nguyễn Phúc Bảo Nhân	Tìm hiểu thuật toán, Sơ lược đề tài, Viết kết luận	100%
Phan Đình Nhân	Tìm hiểu thuật toán, Viết khái niệm tổng quát	100%
Nguyễn Quang Nhật	Tìm hiểu thuật toán, Xây dựng thuật toán, Tiền xử lý	100%
Nguyễn Thị Ngọc Nhi	Tìm hiểu thuật toán, Xây dựng thuật toán, Đánh giá	100%

3. Tài liệu tham khảo

- [1] B. Goethals, “Survey on frequent pattern mining,” University of Helsinki, 2003.
- [2] Nguyen An Te, “Data Mining.2023.Ch4 - Luật kết hợp”, UEH, 2023.
- [3] Hong Cheng et al, “Discriminative Frequent Pattern Analysis for Effective Classification”, University of Illinois, 2007.